FINAL YEAR ENGINEERING PROJECT · DEMO GUIDE

YojanaBench Dashboard — Explanation Guide

India Welfare-Scheme Document Reasoning & Multi-Agent Audit Pipeline

हिंदी: यह गाइड बताती है कि YojanaBench के dashboard को किसी presentation या viva में step-by-step कैसे समझाना है। नarration हिंदी में है और सभी technical terms, metrics तथा widget names English में दिए गए हैं।

English: This document explains how to walk someone through the YojanaBench dashboard. The narration is in Hindi; all technical terms, metrics and widget names are kept in English.

1. Overview — यह project क्या करता है?

हिंदी: YojanaBench भारत की कल्याणकारी योजनाओं (welfare schemes) के लिए एक benchmark और audit system है। यह user की situation और documents को देखकर बताता है कि वह योजना के लिए eligible है या नहीं, कितना benefit मिलेगा, कौन-से documents चाहिए, और अगर appeal करनी हो तो कहाँ करनी है।

English: YojanaBench is a benchmark plus a multi-agent audit pipeline. Given an applicant's situation and documents, it decides eligibility (`eligible` / `ineligible` / `needs_info`), computes the entitlement, lists required documents and routes an appeal.

8-Agent Pipeline (order में)

हिंदी: नीचे दिए 8 agents एक के बाद एक चलते हैं; हर agent को अलग से inspect किया जा सकता है।

#	Agent	काम / Role
1	Corpus	Scheme schemas और guideline clauses load करता है।
2	Intake	Applicant data और submitted documents को normalize करता है।
3	RAG	Hybrid retrieval (BM25 + TF-IDF) से relevant clauses निकालता है।
4	Entitlement	Rules से eligibility और benefit amount calculate करता है।
5	Verification	Independent cross-check; disagreement पर `needs_info` ।
6	Orchestrator	Final verdict + confidence + human-approval gate।
7	Evaluation	EM, Token-F1, verdict accuracy, ECE आदि metrics।
8	Appeal	Grievance hierarchy से appeal draft बनाता है।

2. Navigation — left sidebar

हिंदी: बाईं तरफ sidebar में छह tabs हैं। किसी भी tab पर click करने से उसका page खुलता है; ऊपर title और subtitle बदल जाते हैं।

- **Dashboard** — statistics, benchmark metrics, agent pipeline, accuracy report
- **Audit a Case** — एक application पर पूरा pipeline चलाना
- **Benchmark** — 56 QA pairs पर pipeline को score करना
- **Ablations** — हर component का contribution मापना
- **Scheme Corpus** — 10 schemes का structured data

- **Appeal Routing** — grievance hierarchy और appeal letter

3. Dashboard page — सबसे पहला और main page

3.1 Hero section

हिंदी: सबसे ऊपर project का एक-line introduction और **"Run full benchmark"** button होता है। यह button पूरे 56 QA pairs पर pipeline चलाकर metrics भर देता है।

English: The hero band shows the project tagline and a **Run full benchmark** button that scores all 56 human-verified QA pairs.

3.2 Corpus statistics (stat cards)

हिंदी: यहाँ dataset की size दिखती है — कितनी schemes, guidelines, clauses, और QA pairs हैं। इसे बोलते समय कहें कि यह dataset का proof-of-scale है।

Stat card	Meaning
Schemes in corpus	कुल कल्याणकारी योजनाएँ (10)
Guideline documents	Scheme guideline files (10)
Indexed clauses / chunks	Retrieval index में clauses
Estimated PDF pages	Guideline pages का अनुमान
Human-verified QA pairs	Benchmark items (56)
Counterfactual / edge cases	Boundary & tricky cases की संख्या

3.3 Benchmark metrics + "Accuracy by QA category" chart

हिंदी: "Run full benchmark" दबाने पर यहाँ 10 metric cards भर जाते हैं और नीचे category-wise bar chart बनता है। बोलते समय सबसे important metric — **Verdict accuracy** — पहले बताएं, फिर document F1 और entitlement error।

Metric	क्या मापता है
Verdict accuracy	eligible / ineligible / needs_info सही पहचानने का %
Answer accuracy	जिन items का Token-F1 ≥ 0.5
Token F1	Predicted text और reference का overlap
Exact match (EM)	पूरा जवाब word-to-word match
Entitlement error	राशि में औसत गलती (₹)
Document F1	Required documents की सही list
Calibration (ECE)	Confidence कितना honest है (कम = बेहतर)
Edge / Base accuracy	मुश्किल cases और साधारण cases पर accuracy

3.4 Agent pipeline diagram

हिंदी: यहाँ 8 agents के chips दिखते हैं। बताएं कि हर agent independent है और Orchastrator low confidence या cross-check disagreement पर **human-approval gate** खोल देता है।

3.5 Accuracy report card (new)

हिंदी: **"Generate report"** button दबाने पर चार tables बनती हैं। यह wahi report है जो `python report.py` CSV में निकालता है। Viva में इसे "evidence" के रूप में दिखाएं।

- **Overall metrics** — सभी headline numbers एक table में
- **Per-scheme accuracy** — हर scheme का verdict accuracy और mean F1
- **Edge-case vs base-case** — मुश्किल vs साधारण cases की तुलना
- **Ablation study** — हर component हटाने पर performance में गिरावट

> **मुख्य बात:** यह project deterministic maths use करता है, इसलिए entitlement error almost 0 आता है। LLM सिर्फ explanation सुधारने के लिए optional है।

4. Audit a Case page

हिंदी: यह page एक असली application पर पूरा pipeline चलाता है। बाएँ form में applicant की details भरें, documents tick करें, और **"Run audit"** दबाएँ।

> **Demo flow:** Sample case चुनें → Target scheme चुनें → fields auto-fill → documents tick करें → Run audit → result देखें।

Result element	अर्थ
Verdict card	Final decision + confidence bar
Computed entitlement	निकाली गई benefit राशि (₹)
Evidence citations	हर verdict के पीछे clause IDs
Agent trace timeline	हर agent ने क्या किया
Appeal letter	Auto-generated appeal draft

हिंदी: **"Polish explanation with local LLM"** checkbox optional है — Ollama न मिले तो system deterministic explanation देता है।

5. Benchmark page

हिंदी: यहाँ scheme और category filter लगाकर benchmark चल सकते हैं। नीचे हर QA item की row दिखती है — question, ground truth, prediction, EM और F1। इसे "full transparency" के रूप में बताएँ कि model का हर जवाब inspect किया जा सकता है।

- **Filters:** All schemes / category (eligibility, entitlement, documents, appeal)
- **Per-category breakdown chart** — किस category में accuracy कैसी है
- **Results table** — ID, Category, Question, Ground, Predicted, EM, F1

6. Ablation Study page

हिंदी: यह project का research contribution है। हम एक-एक component हटाकर देखते हैं कि performance कितनी गिरती है। **"Run ablation study"** दबाएँ।

Variant	क्या बदला
full	पूरा 8-agent pipeline (baseline)
no_verification	Verification cross-check हटाया गया
llm_math	Deterministic maths की जगह naive estimation
no_counterfactuals	सिर्फ base items (edge cases हटाए)

हिंदी: Result से सिद्ध होता है: Verification हटाने पर verdict accuracy लगभग **6% गिरती** है, और naive maths पर entitlement error बहुत बढ़ जाता है।

7. Scheme Corpus page

हिंदी: इस page पर 10 schemes के cards हैं। हर card खोलकर eligibility criteria, entitlement rules, required documents और appeal hierarchy देख सकते हैं। यह “structured corpus“ को दर्शाता है।

8. Appeal Routing page

हिंदी: Scheme चुनने पर उसकी grievance hierarchy दिखती है — कौन-सा authority, किस level पर, और कितने दिन की deadline। यह बताएँ कि verdict के बाद citizen को appeal का रास्ता भी दिखाते हैं।

9. Viva / Demo — कैसे explain करें (60-second script)

Step 1 (10s): "YojanaBench welfare schemes के लिए India का पहला document-reasoning benchmark और audit pipeline है।"

Step 2 (15s): Dashboard → corpus stats दिखाएँ → 10 schemes, 56 QA pairs।

Step 3 (15s): "Run full benchmark" → metric cards → Verdict accuracy, Document F1, Entitlement error।

Step 4 (10s): Accuracy report → चार tables दिखाएँ।

Step 5 (10s): Ablations → "Verification हटाने पर accuracy गिरती है।"

Step 6 (10s): Audit a Case → एक live example चलाएँ।

10. Glossary — technical terms (English)

Term	Meaning
Verdict accuracy	Primary metric — correct eligible/ineligible/needs_info decisions.
Entitlement	Computed benefit amount in rupees.
Evidence clause	Source guideline clause that supports a decision.
Counterfactual / edge case	Boundary or adversarially-changed scenario.
Calibration (ECE)	How well confidence matches actual correctness.
Human-approval gate	Flag telling a human to review a low-confidence case.
Ablation	Removing a component to measure its contribution.

YojanaBench · Dashboard Explanation Guide · Hindi narration with English content · Generated automatically from the project.